

# Famílias conjugadas e alguns modelos paramétricos

**Prof. Vinícius D. Mayrink**

EST088 - Inferência Bayesiana

Sala: 4073

Email: [vdm@est.ufmg.br](mailto:vdm@est.ufmg.br)

1º semestre de 2025

## 3.1 - Famílias conjugadas

O tema a ser tratado nesta parte do curso é muito importante para nos orientar sobre como escolher distribuições *a priori* de maneira apropriada para garantir facilidade nas contas do Teorema de Bayes que irão determinar a distribuição *a posteriori*.

Em muitos problemas práticos iremos optar por **distribuições a priori conjugadas**. Para explicar este assunto, iniciamos com a definição a seguir.

**Definição:** Seja  $\mathcal{F} = \{f_{\mathbf{Y}|\theta}(\mathbf{y}) : \theta \in \Theta\}$  uma família de distribuições relacionadas à amostra  $\mathbf{Y}$ . Uma classe  $\mathcal{C}$  de distribuições é reconhecida como família conjugada em relação a  $\mathcal{F}$ , se para todo  $f_{\mathbf{Y}|\theta}(\mathbf{y}) \in \mathcal{F}$  e  $f_{\theta}(\theta) \in \mathcal{C}$ , temos  $f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) \in \mathcal{C}$ .

Em outras palavras, se a distribuição *a priori*  $f_{\theta}(\theta)$  escolhida é membro de uma família de distribuições que conjugam com o modelo estabelecido pela verossimilhança  $f_{\mathbf{Y}|\theta}(\mathbf{y})$ , então a distribuição *a posteriori*  $f_{\theta|\mathbf{Y}}(\theta|\mathbf{y})$  também será membro da mesma família na qual  $f_{\theta}(\theta)$  é integrante.

Cuidado! A classe  $\mathcal{C}$  pode ser bastante ampla.

Se  $\mathcal{C} = \{\text{todas as distribuições}\}$  e  $\mathcal{F}$  é qualquer família de distribuições amostrais. Note que  $\mathcal{C}$  é conjugada com respeito a  $\mathcal{F}$  visto que qualquer distribuição *a posteriori* será membro de  $\mathcal{C}$ .

A classe  $\mathcal{C}$  poderia ser também muito restrita.

Suponha, por exemplo, que  $\mathcal{C} = \{f_{\theta}(\theta) : f_{\theta}(\theta = \theta_0) = 1, \theta_0 \in \mathcal{A}\}$  para algum conjunto não nulo  $\mathcal{A}$ .

Isto significa que:  $f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) \propto f_{\mathbf{Y}|\theta}(\mathbf{y}) f_{\theta}(\theta) = \begin{cases} f_{\mathbf{Y}|\theta}(\mathbf{y}) \times 1, & \text{se } \theta = \theta_0. \\ f_{\mathbf{Y}|\theta}(\mathbf{y}) \times 0, & \text{se } \theta \neq \theta_0. \end{cases}$

Portanto segue que:  $f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) = \begin{cases} k \times f_{\mathbf{Y}|\theta}(\mathbf{y}), & \text{se } \theta = \theta_0. \\ 0, & \text{se } \theta \neq \theta_0. \end{cases}$

Conclusão:  $f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) = 1$ , se e somente se  $\theta = \theta_0$ , portanto,  $\mathcal{C}$  é conjugada a qualquer família de distribuições.

Veja que quando uma probabilidade nula é atribuída a um subconjunto dos possíveis valores de  $\theta$ , nenhuma informação observada irá mudar a especificação (o que é claramente inadequado).

**Regra de Cromwell (Lindley):** Devemos sempre associar uma probabilidade *a priori* não nula para cada possível valor de  $\theta$ , mesmo que alguns deles sejam julgados como muito improváveis.

Exemplo: Considere  $Y_1, Y_2, \dots, Y_n$  uma amostra aleatória tal que  $Y_i|\theta \sim \text{Bernoulli}(\theta)$ . Dado  $\theta$ , adote independência condicional dos  $Y_i$ 's.

Verossimilhança:  $f_{\mathbf{Y}|\theta}(\mathbf{y}) = \theta^{\sum_{i=1}^n y_i} (1 - \theta)^{n - \sum_{i=1}^n y_i}$ .

Espaço paramétrico:  $\theta \in [0, 1]$ .

A distribuição *a priori* escolhida pelo pesquisador é discreta e coloca massa de probabilidade em apenas 4 valores dentro do intervalo  $[0, 1]$ :

Denote:  $\theta_1 = 0.1$ ,  $\theta_2 = 0.2$ ,  $\theta_3 = 0.4$  e  $\theta_4 = 0.9$ .

$f_{\theta}(\theta_1) = 0.1$ ,  $f_{\theta}(\theta_2) = 0.2$ ,  $f_{\theta}(\theta_3) = 0.5$  e  $f_{\theta}(\theta_4) = 0.2$ .

Regra de Bayes para obter a distribuição *a posteriori*:

$$f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) = \frac{\theta^{\sum_{i=1}^n y_i} (1-\theta)^{n-\sum_{i=1}^n y_i} f_{\theta}(\theta)}{\sum_{j=1}^4 \theta_j^{\sum_{i=1}^n y_i} (1-\theta_j)^{n-\sum_{i=1}^n y_i} f_{\theta}(\theta_j)}$$

$$f_{\theta|\mathbf{Y}}(\theta_1|\mathbf{y}) = \frac{(0.1)^{\sum_{i=1}^n y_i} (1-0.1)^{n-\sum_{i=1}^n y_i} f_{\theta}(0.1)}{\sum_{j=1}^4 \theta_j^{\sum_{i=1}^n y_i} (1-\theta_j)^{n-\sum_{i=1}^n y_i} f_{\theta}(\theta_j)} \propto (0.1)^{\sum_{i=1}^n y_i} (0.9)^{n-\sum_{i=1}^n y_i} 0.1.$$

O cálculo acima foi feito para um dos valores com probabilidade não nula na especificação *a priori*. A próxima avaliação considera o valor  $\theta = 0.5$  para o qual foi atribuído probabilidade 0 *a priori*.

$$f_{\theta|\mathbf{Y}}(0.5|\mathbf{y}) = \frac{(0.5)^{\sum_{i=1}^n y_i} (1-0.5)^{n-\sum_{i=1}^n y_i} f_{\theta}(0.5)}{\sum_{j=1}^4 \theta_j^{\sum_{i=1}^n y_i} (1-\theta_j)^{n-\sum_{i=1}^n y_i} f_{\theta}(\theta_j)} \\ \propto (0.5)^{\sum_{i=1}^n y_i} (0.5)^{n-\sum_{i=1}^n y_i} 0 = 0.$$

Conclusão: para qualquer tamanho amostral  $n$ , a probabilidade *a posteriori* de  $\theta = 0.5$  será 0, pois foi admitida uma probabilidade nula para esse valor *a priori*.

A classe  $\mathcal{C}$  precisa ser ampla o bastante para assegurar uma conveniente elicitaco *a priori* e, ao mesmo tempo, restrita o bastante para que a definio de conjugaco seja til.

**Definio:** Seja  $X$  uma varivel aleatria associada  seguinte classe de distribuices  $\mathcal{C} = \{f_{X|\lambda}(x) : \lambda \in \Lambda\}$ . A classe  $\mathcal{C}$   dita *fechada sob multiplicaco ou amostragem* se para todo  $f_{X|\lambda_1}(x)$  e  $f_{X|\lambda_2}(x) \in \mathcal{C}$ , existe um  $k$  tal que  $k \times f_{X|\lambda_1}(x) \times f_{X|\lambda_2}(x) \in \mathcal{C}$ .

**Exemplo:** Seja  $\mathcal{C}$  a classe de distribuices  $\text{Gama}(a_i, b_i)$  com  $a_i > 0$  e  $b_i > 0$ . Denote  $\lambda_i = (a_i, b_i)$ .

$$f_{X|\lambda_1}(x) \times f_{X|\lambda_2}(x) = \frac{b_1^{a_1}}{\Gamma(a_1)} x^{a_1-1} \exp\{-b_1 x\} \frac{b_2^{a_2}}{\Gamma(a_2)} x^{a_2-1} \exp\{-b_2 x\} \\ \propto x^{a_1+a_2-2} \exp\{-(b_1 + b_2)x\}.$$

Temos o ncleo da  $\text{Ga}(a_1 + a_2 - 1, b_1 + b_2)$ .

O “fechamento”  muito importante na busca por famlias conjugadas.

Suponha que iremos escolher nossa especificação *a priori* sobre  $\theta$  dentro da classe de distribuições  $\mathcal{C} = \{f_{\theta|\lambda}(\theta) : \lambda \in \Lambda\}$ . Admita também que esta classe é fechada sob multiplicação e amostragem.

Se o núcleo da verossimilhança  $f_{\mathbf{Y}|\theta}(\mathbf{y})$  se assemelha ao núcleo da classe  $\mathcal{C}$ , que é fechada sob multiplicação, então as distribuições *a priori* e *a posteriori* irão necessariamente pertencer à mesma classe  $\mathcal{C}$  (dizemos que existe **conjugação**).

Procedimento para determinar a classe conjugada:

- 1 Identificar a classe  $\mathcal{C}$  de distribuições para  $\theta$  cujos membros são proporcionais a  $f_{\mathbf{Y}|\theta}(\mathbf{y})$ .
- 2 Verificar se  $\mathcal{C}$  é fechada sob multiplicação e amostragem.

Se, além disso, para qualquer verossimilhança  $f_{\mathbf{Y}|\theta}(\mathbf{y})$  obtida de uma família  $\mathcal{F}$ , existe uma constante  $k$  definindo  $f_{\theta}(\theta) = k f_{\mathbf{Y}|\theta}(\mathbf{y})$ , então a classe  $\mathcal{C}$ , de todas as p.d.f.'s ou p.m.f.'s deste tipo, é dita família conjugada natural com respeito ao modelo com verossimilhança  $f_{\mathbf{Y}|\theta}(\mathbf{y})$ .

Exemplo: Seja  $(Y_i|\theta) \sim \text{Bernoulli}(\theta)$ ,  $i = 1, 2, \dots, n$ . O teorema de Bayes fornece:  $f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) \propto f_{\mathbf{Y}|\theta}(\mathbf{y}) f_{\theta}(\theta) \propto \theta^t(1-\theta)^{n-t} f_{\theta}(\theta)$ , sendo  $t = \sum_{i=1}^n y_i$ .

Desejamos determinar uma distribuição *a priori* conjugada para  $\theta$ .

Considere  $k^{-1} = \frac{\Gamma(t+1)\Gamma(n-t+1)}{\Gamma(t+1+n-t+1)}.$

Veja que:  $k f_{\mathbf{Y}|\theta}(\mathbf{y}) = \frac{\Gamma(t+1+n-t+1)}{\Gamma(t+1)\Gamma(n-t+1)} \theta^t(1-\theta)^{n-t}.$

Temos acima a p.d.f. da  $\text{Beta}(t+1, n-t+1)$ . Portanto, a classe de distribuições Beta com parâmetros inteiros ( $t$  é inteiro) é uma família conjugada natural para o modelo Bernoulli.

Se considerarmos todos os possíveis valores positivos para os parâmetros da Beta (não somente os valores inteiros), a classe de distribuições Beta será ampliada, e ainda teremos uma distribuição conjugada, mas ela não é a conjugada natural.



Famílias conjugadas naturais são úteis visto que um significado objetivo pode ser atribuído aos **hiperparâmetros** envolvidos. No último exemplo, suponha que exista um experimento prévio para o qual obtemos  $t_0$  sucessos em  $n_0$  realizações. Então a conjugada natural será a  $\text{Beta}(t_0 + 1, n_0 - t_0 + 1)$ .

**Nomenclatura (esclarecendo):** hiperparâmetro é um parâmetro que indexa a distribuição *a priori* especificada para um outro parâmetro que, por sua vez, indexa a distribuição de  $\mathbf{Y}$ .

No modelo Bayesiano  $Y_i \sim \text{Bernoulli}(\theta)$  e  $\theta \sim \text{Beta}(a, b)$ , temos que  $a$  e  $b$  são hiperparâmetros.

Para fixar melhor os conceitos apresentados sobre conjugação, nos próximos slides iremos avaliar algumas famílias conjugadas importantes.

As principais famílias conjugadas.

**Distribuição Binomial:** A família de distribuições Beta é conjugada com o modelo Bernoulli ou Binomial.

O caso Bernoulli já foi trabalhado em vários exemplos discutidos neste curso (rever slides).

O caso Binomial será detalhado em duas situações a seguir.

Situação 1: Seja  $\mathbf{Y} = \{Y_1, Y_2, \dots, Y_n\}$  uma amostra aleatória tal que  $Y_i|\theta \sim \text{Bernoulli}(\theta)$  são i.i.d. por independência condicional. Admita que a informação amostral que é passada ao pesquisador é  $W = \sum_{i=1}^n Y_i$  e  $n$ .

Note que  $W$  é o número de sucessos em  $n$  experimentos Bernoullis. Temos  $W \sim \text{Binomial}(n, \theta)$ , pois é a soma de ensaios Bernoullis independentes.

Espaço paramétrico:  $\theta \in [0, 1]$ .

Verossimilhança:  $f_{W|\theta}(w) = \binom{n}{w} \theta^w (1 - \theta)^{n-w}$ . Sem produtório!

Distribuição *a priori*:  $\theta \sim \text{Beta}(a, b)$ .

Distribuição *a posteriori*:  $f_{\theta|W}(\theta|w) \propto f_{W|\theta}(w) f_{\theta}(\theta)$

$$f_{\theta|W}(\theta|w) \propto \binom{n}{w} \theta^w (1 - \theta)^{n-w} \frac{\Gamma(a+b)}{\Gamma(a) \Gamma(b)} \theta^{a-1} (1 - \theta)^{b-1}$$

Termos em destaque são constantes (não dependem de  $\theta$ ) e podem ser incorporados na constante normalizadora.

$$\propto \theta^w (1 - \theta)^{n-w} \theta^{a-1} (1 - \theta)^{b-1}$$

$$\propto \theta^{a+w-1} (1 - \theta)^{b+n-w-1}.$$

A expressão acima é o núcleo da  $\text{Beta}(a^*, b^*)$

com  $a^* = a + w$  e  $b^* = b + n - w$ .

As distribuições *a priori*  $\theta \sim \text{Beta}(a, b)$  e *a posteriori*  $\theta|W \sim \text{Beta}(a^*, b^*)$  são da família Beta.

Situação 2: Seja  $\mathbf{Y} = \{Y_1, Y_2, \dots, Y_n\}$  uma amostra aleatória tal que  $Y_i|\theta \sim \text{Binomial}(m, \theta)$  são i.i.d. por independência condicional. Veja que  $Y_i$  é o número de sucessos em  $m$  ensaios Bernoullis.

Espaço paramétrico:  $\theta \in [0, 1]$ .

Verossimilhança:  $f_{\mathbf{Y}|\theta}(\mathbf{y}) = \prod_{i=1}^n \binom{m}{y_i} \theta^{y_i} (1 - \theta)^{m-y_i}$ . Com produtório!

Distribuição *a priori*:  $\theta \sim \text{Beta}(a, b)$ .

Distribuição *a posteriori*:  $f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) \propto f_{\mathbf{Y}|\theta}(\mathbf{y}) f_{\theta}(\theta)$

$$f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) \propto \prod_{i=1}^n \binom{m}{y_i} \theta^{y_i} (1 - \theta)^{m-y_i} \frac{\Gamma(a+b)}{\Gamma(a) \Gamma(b)} \theta^{a-1} (1 - \theta)^{b-1}$$
$$\propto \left[ \prod_{i=1}^n \binom{m}{y_i} \right] \theta^{\sum_{i=1}^n y_i} (1 - \theta)^{\sum_{i=1}^n (m-y_i)} \frac{\Gamma(a+b)}{\Gamma(a) \Gamma(b)} \theta^{a-1} (1 - \theta)^{b-1}.$$

Termos em destaque são constantes (não dependem de  $\theta$ ) e podem ser incorporados na constante normalizadora.

$$f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) \propto \theta^{\sum_{i=1}^n y_i} (1 - \theta)^{nm - \sum_{i=1}^n y_i} \theta^{a-1} (1 - \theta)^{b-1}.$$

$$\propto \theta^{a + \sum_{i=1}^n y_i - 1} (1 - \theta)^{b + nm - \sum_{i=1}^n y_i - 1}.$$

É possível identificar acima o núcleo da  $\text{Beta}(a^*, b^*)$

com  $a^* = a + \sum_{i=1}^n y_i$  e  $b^* = b + nm - \sum_{i=1}^n y_i$ .

Novamente, as distribuições *a priori*  $\theta \sim \text{Beta}(a, b)$  e *a posteriori*  $\theta|\mathbf{Y} \sim \text{Beta}(a^*, b^*)$  são da família Beta.

**Distribuição Exponencial:** A família de distribuições Gama é conjugada com o modelo Exponencial.

Este caso também já foi discutido neste curso (rever slides).

Seja  $\mathbf{Y} = \{Y_1, Y_2, \dots, Y_n\}$  uma amostra aleatória da  $\text{Exp}(\theta)$  com média  $1/\theta > 0$ . Assuma independência condicional dos  $Y_i$ 's dado  $\theta$ .

Espaço paramétrico:  $\theta \in \mathbb{R}^+$ .

Verossimilhança:  $f_{\mathbf{Y}|\theta}(\mathbf{y}) = \prod_{i=1}^n \theta \exp\{-\theta y_i\} = \theta^n \exp\{-\theta \sum_{i=1}^n y_i\}$ .

Distribuição *a priori*:  $\theta \sim \text{Ga}(a, b)$ .

Distribuição *a posteriori*:  $f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) \propto f_{\mathbf{Y}|\theta}(\mathbf{y}) f_{\theta}(\theta)$

$$\propto \theta^n \exp\{-\theta \sum_{i=1}^n y_i\} \frac{b^a}{\Gamma(a)} \theta^{a-1} \exp\{-b\theta\}$$

Termos em destaque são constantes (não dependem de  $\theta$ ) e podem ser incorporados na constante normalizadora.

$$\propto \theta^{a+n-1} \exp\{-(b + \sum_{i=1}^n y_i)\theta\}.$$

Este é o núcleo da  $\text{Ga}(a^*, b^*)$ , com  $a^* = a + n$  e  $b^* = b + \sum_{i=1}^n y_i$ .

Conclusão: as distribuições *a priori*  $\theta \sim \text{Ga}(a, b)$  e *a posteriori*  $\theta|\mathbf{Y} \sim \text{Ga}(a^*, b^*)$  são da família Gama.

$$E(\theta|\mathbf{Y}) = a^*/b^* = \frac{a+n}{b+\sum_{i=1}^n y_i} = \frac{b}{b+\sum_{i=1}^n y_i} \frac{a}{b} + \frac{\sum_{i=1}^n y_i}{b+\sum_{i=1}^n y_i} \frac{n}{\sum_{i=1}^n y_i}.$$

Veja que  $n \rightarrow \infty$  implica em  $E(\theta|\mathbf{Y}) \approx 1/\bar{y}$ .

Perceba que a distribuição Exponencial é um caso particular da distribuição Gama.

Se  $Y_i|\theta \sim \text{Ga}(1, \theta)$ , então  $Y_i|\theta \sim \text{Exp}(\theta)$ .

f.d.p.'s:  $\frac{\theta^1}{\Gamma(1)} y_i^{1-1} \exp\{-\theta y_i\} = \theta \exp\{-\theta y_i\}$  para  $y_i > 0$  e  $\theta > 0$ .

Seja  $\mathbf{Y} = \{Y_1, Y_2, \dots, Y_n\}$  uma amostra aleatória da  $\text{Ga}(\kappa, \theta)$  com parâmetro de forma  $\kappa$  conhecido. Admita independência condicional dos  $Y_i$ 's dado  $\theta$ . A família de distribuições Gama é conjugada com a família  $\text{Ga}(\kappa, \theta)$ . Note que o parâmetro alvo a ser estimado é o  $\theta$ .

Exercício: Mostre este resultado! Obtenha a distribuição *a posteriori*.

**Distribuição Poisson:** A família de distribuições Gama é conjugada com o modelo Poisson.

Reveja os slides! Este caso também já foi discutido anteriormente.

Considere  $\mathbf{Y} = \{Y_1, Y_2, \dots, Y_n\}$  uma amostra aleatória da  $\text{Poisson}(\theta)$ .  
Adote independência condicional entre os  $Y_i$ 's dado a taxa  $\theta$ .

Espaço paramétrico:  $\theta \in \mathbb{R}^+$ .

Verossimilhança:  $f_{\mathbf{Y}|\theta}(\mathbf{y}) = \prod_{i=1}^n \frac{\theta^{y_i}}{y_i!} \exp\{-\theta\} = \frac{\theta^{\sum_{i=1}^n y_i}}{\prod_{i=1}^n y_i!} \exp\{-n\theta\}$ .

Distribuição *a priori*:  $\theta \sim \text{Ga}(a, b)$ .



Distribuição *a posteriori*:  $f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) \propto f_{\mathbf{Y}|\theta}(\mathbf{y}) f_{\theta}(\theta)$

$$\propto \frac{\theta^{\sum_{i=1}^n y_i}}{\prod_{i=1}^n y_i!} \exp\{-n\theta\} \frac{b^a}{\Gamma(a)} \theta^{a-1} \exp\{-b\theta\}$$

Termos em destaque são constantes (não dependem de  $\theta$ ) e podem ser incorporados na constante normalizadora.

$$f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) \propto \theta^{\sum_{i=1}^n y_i} \exp\{-n\theta\} \theta^{a-1} \exp\{-b\theta\}.$$

$$\propto \theta^{a+\sum_{i=1}^n y_i-1} \exp\{-(b+n)\theta\}.$$

Temos aqui o núcleo da  $\text{Ga}(a^*, b^*)$ , com  $a^* = a + \sum_{i=1}^n y_i$  e  $b^* = b + n$ .

Conclusão: as distribuições *a priori*  $\theta \sim \text{Ga}(a, b)$  e *a posteriori*  $\theta|\mathbf{Y} \sim \text{Ga}(a^*, b^*)$  são da família Gama.

$$E(\theta|\mathbf{Y}) = a^*/b^* = \frac{a+\sum_{i=1}^n y_i}{b+n} = \frac{b}{b+n} \frac{a}{b} + \frac{n}{b+n} \bar{y}.$$

Veja que  $n \rightarrow \infty$  implica em  $E(\theta|\mathbf{Y}) \approx \bar{y}$ .

**Distribuição Geométrica:** A família de distribuições Beta é conjugada com o modelo Geométrico. Seja  $\mathbf{Y} = \{Y_1, Y_2, \dots, Y_n\}$  uma amostra tal que  $Y_i | \theta \sim \text{Geométrica}(\theta)$ . Adote independência condicional dos  $Y_i$ 's dado  $\theta$ .

A Geométrica refere-se ao caso em que realizam-se sucessivos experimentos (sucesso e fracasso) até a ocorrência do 1º sucesso.  $Y_i$  é o  $n^\circ$  de fracassos antes do evento sucesso. Esta é uma variável aleatória discreta com suporte  $y_i \in \{0, 1, 2, 3, \dots\}$ .

Espaço paramétrico:  $\theta \in [0, 1]$  é a probabilidade de sucesso.

Verossimilhança:  $f_{\mathbf{Y}|\theta}(\mathbf{y}) = \prod_{i=1}^n \theta(1-\theta)^{y_i} = \theta^n (1-\theta)^{\sum_{i=1}^n y_i}$ .

Distribuição *a priori*:  $\theta \sim \text{Beta}(a, b)$ .

Distribuição *a posteriori*:  $f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) \propto f_{\mathbf{Y}|\theta}(\mathbf{y}) f_{\theta}(\theta)$

$$\propto \theta^n (1-\theta)^{\sum_{i=1}^n y_i} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \theta^{a-1} (1-\theta)^{b-1} \propto \theta^{a+n-1} (1-\theta)^{b+\sum_{i=1}^n y_i-1}$$

Este é o núcleo da  $\text{Beta}(a^*, b^*)$ , com  $a^* = a + n$  e  $b^* = b + \sum_{i=1}^n y_i$ .

Conclusão: a distribuição *a priori*  $\theta \sim \text{Beta}(a, b)$  e a *a posteriori*  $\theta | \mathbf{Y} \sim \text{Beta}(a^*, b^*)$  são da família Beta.

**Distribuição  $N(\mu, \sigma^2)$  com variância conhecida:** A família de distribuições Normais é conjugada com o modelo Normal para estimar a média  $\mu$ .

Seja  $\mathbf{Y} = \{Y_1, Y_2, \dots, Y_n\}$  uma amostra aleatória da  $N(\mu, \sigma^2)$ . Admita independência condicional dos  $Y_i$ 's dado  $\mu$ .

Espaço paramétrico:  $\mu \in \mathbb{R}$ .

Verossimilhança:  $f_{\mathbf{Y}|\mu}(\mathbf{y}) = \prod_{i=1}^n (2\pi\sigma^2)^{-1/2} \exp\{-\frac{1}{2\sigma^2}(y_i - \mu)^2\}$ .

$$= \prod_{i=1}^n (2\pi\sigma^2)^{-1/2} \exp\{-\frac{1}{2\sigma^2}(y_i^2 - 2\mu y_i + \mu^2)\}.$$

$$= (2\pi\sigma^2)^{-n/2} \exp\{-\frac{1}{2\sigma^2}(\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2)\}.$$

$$= (2\pi\sigma^2)^{-n/2} \exp\{-\frac{1}{2\sigma^2}(\sum_{i=1}^n y_i^2)\} \exp\{-\frac{1}{2\sigma^2}(-2\mu \sum_{i=1}^n y_i + n\mu^2)\}.$$

Distribuição *a priori*:  $\mu \sim N(m, v)$ .

Distribuição *a posteriori*:  $f_{\mu|\mathbf{Y}}(\mu|\mathbf{y}) \propto f_{\mathbf{Y}|\mu}(\mathbf{y}) f_{\mu}(\mu)$

$$\propto (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2}\left(\sum_{i=1}^n y_i^2\right)\right\} \exp\left\{-\frac{1}{2\sigma^2}\left(-2\mu \sum_{i=1}^n y_i + n\mu^2\right)\right\} \times \\ \times (2\pi\nu)^{-1/2} \exp\left\{-\frac{1}{2\nu}(\mu - m)^2\right\}.$$

$$\propto (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2}\left(\sum_{i=1}^n y_i^2\right)\right\} \exp\left\{-\frac{1}{2\sigma^2}\left(-2\mu \sum_{i=1}^n y_i + n\mu^2\right)\right\} \times \\ \times (2\pi\nu)^{-1/2} \exp\left\{-\frac{1}{2\nu}m^2\right\} \exp\left\{-\frac{1}{2\nu}(\mu^2 - 2\mu m)\right\}.$$

Termos destacados em vermelho são constantes (não dependem de  $\mu$ ). Eles serão incorporados na constante normalizadora.

$$f_{\mu|\mathbf{Y}}(\mu|\mathbf{y}) \propto \exp\left\{-\frac{1}{2}\left(-2\mu\frac{\sum_{i=1}^n y_i}{\sigma^2} + \frac{n}{\sigma^2}\mu^2\right)\right\} \exp\left\{-\frac{1}{2}\left(\frac{1}{v}\mu^2 - 2\mu\frac{m}{v}\right)\right\}.$$

$$\propto \exp\left\{-\frac{1}{2}\left[\mu^2\left(\frac{n}{\sigma^2} + \frac{1}{v}\right) - 2\mu\left(\frac{\sum_{i=1}^n y_i}{\sigma^2} + \frac{m}{v}\right)\right]\right\}.$$

$$\propto \exp\left\{-\frac{1}{2}\left(\frac{n}{\sigma^2} + \frac{1}{v}\right)\left[\mu^2 - 2\mu\left(\frac{n}{\sigma^2} + \frac{1}{v}\right)^{-1}\left(\frac{\sum_{i=1}^n y_i}{\sigma^2} + \frac{m}{v}\right)\right]\right\}.$$

Temos aqui o núcleo da distribuição  $N(m^*, v^*)$ , com:

- O trecho em vermelho fornece:  $v^* = \left(\frac{n}{\sigma^2} + \frac{1}{v}\right)^{-1}$ .
- O trecho em verde estabelece:  $m^* = v^*\left(\frac{\sum_{i=1}^n y_i}{\sigma^2} + \frac{m}{v}\right)$ .

Conclusão: a distribuição *a priori*  $\mu \sim N(m, v)$  e a *posteriori*  $\mu|\mathbf{Y} \sim N(m^*, v^*)$  são da família Normal.

Estudo simulado usando o modelo  $N(\mu, \sigma^2)$  com  $\sigma^2$  conhecido:

Passos para gerar dados artificiais (comandos R):

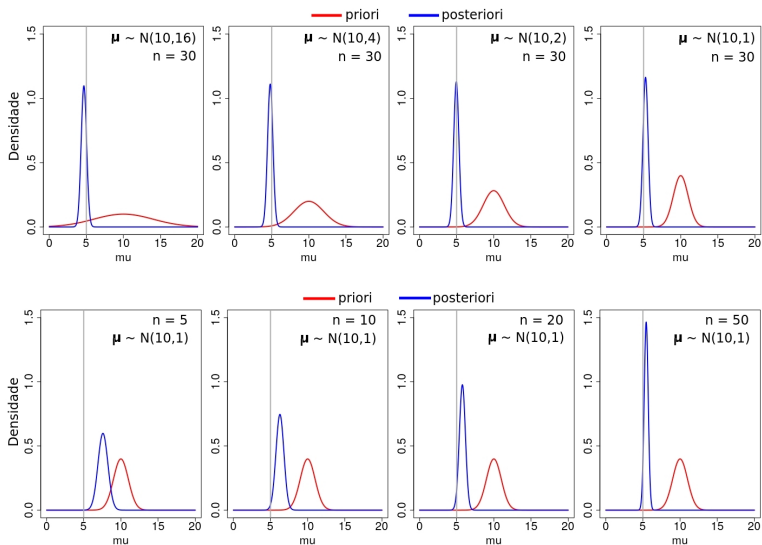
```
mureal = 5                                # defina o verdadeiro valor de mu;  
sig2real = 4                              # defina o verdadeiro valor de sigma2;  
n = 30                                    # defina o tamanho amostral;  
y = rnorm(n, mureal, sqrt(sig2real))      # gere observações da Normal.
```

Na prática, não conhecemos o valor real de  $\mu$ . Ele é usado acima apenas para gerar a amostra  $\mathbf{y}$ . O valor real  $\sigma^2 = 4$  é conhecido nesta aplicação.

Os gráficos a seguir mostram a distribuição *a posteriori* perante diferentes especificações *a priori* e diferentes valores de  $n$ .

Comandos para cálculo da f.d.p. *a priori* e *a posteriori*:

```
mu = seq(0.01, 20, 0.01)  
prior = dnorm(mu, m, sqrt(v))  
vs = 1 / ( n/sig2real + 1/v )  
ms = vs * ( sum(y)/sig2real + m/v )  
post = dnorm(mu, ms, sqrt(vs))
```



## Comentários sobre os gráficos no slide anterior:

- As distribuições *a priori* estão centradas no valor 10. Note que  $\mu_{\text{real}} = 5$ , então a informação *a priori* está equivocada.
- Nos casos  $n = 30$ , conforme  $\text{Var}(\mu)$  diminui, a f.d.p. *a posteriori* é muito pouco afetada; há um ligeiro deslocamento à direita no cenário mais informativo com  $\mu \sim N(10, 1)$ . A verossimilhança tende a ser dominante quando  $n = 30$ .
- Para  $n = 5$ , a especificação equivocada  $\mu \sim N(10, 1)$  tem grande impacto e vicia o resultado *a posteriori* em azul (f.d.p. azul concentra massa de probabilidade longe de  $\mu_{\text{real}} = 5$ ).
- Conforme  $n$  aumenta, a verossimilhança tende a dominar a informação *a priori* e assim a f.d.p. *a posteriori* passa a concentrar sua massa de probabilidade próximo de  $\mu_{\text{real}} = 5$ .



**Distribuição  $N(\mu, \sigma^2)$  com média conhecida:** A família de distribuições Gama Inversa é conjugada com o modelo Normal para estimar a variância  $\sigma^2$ .

Seja  $\mathbf{Y} = \{Y_1, Y_2, \dots, Y_n\}$  uma amostra aleatória da  $N(\mu, \sigma^2)$ . Admita independência condicional entre os  $Y_i$ 's dado  $\sigma^2$ .

Espaço paramétrico:  $\sigma^2 \in \mathbb{R}^+$ .

Verossimilhança:  $f_{\mathbf{Y}|\sigma^2}(\mathbf{y}) = \prod_{i=1}^n (2\pi\sigma^2)^{-1/2} \exp\{-\frac{1}{2\sigma^2}(y_i - \mu)^2\}$ .

$$= \prod_{i=1}^n (2\pi\sigma^2)^{-1/2} \exp\{-\frac{1}{2\sigma^2}(y_i^2 - 2\mu y_i + \mu^2)\}.$$

$$= (2\pi)^{-n/2} (\sigma^2)^{-n/2} \exp\{-\frac{1}{2\sigma^2}(\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2)\}.$$

Distribuição *a priori*:  $\sigma^2 \sim \text{Gl}(a, b)$ .

Gl = Gama Inversa.


**Definição:** Seja  $X$  uma variável aleatória contínua com distribuição **Gama Inversa** (ou Gama Invertida), iremos denotar  $X \sim \text{GI}(a, b)$  com  $a > 0$  e  $b > 0$ . Sua f.d.p é dada por:

$$\frac{b^a}{\Gamma(a)} x^{-a-1} \exp\{-b/x\} \quad \text{para } x > 0.$$

Além disso temos:  $E(X) = \frac{b}{a-1}$  e  $\text{Var}(X) = \frac{b^2}{(a-1)^2 (a-2)}$

$E(X)$  existe para  $a > 1$  e  $\text{Var}(X)$  existe para  $a > 2$ .

Observação: Se  $W \sim \text{Ga}(a, b)$ , então  $1/W \sim \text{GI}(a, b)$ .



$$\begin{aligned} \text{Distribuição } a \text{ posteriori: } f_{\sigma^2|\mathbf{Y}}(\sigma^2|\mathbf{y}) &\propto f_{\mathbf{Y}|\sigma^2}(\mathbf{y}) f_{\sigma^2}(\sigma^2) \\ &\propto (2\pi)^{-n/2} (\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2}(\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2)\right\} \times \\ &\quad \times \frac{b^a}{\Gamma(a)} (\sigma^2)^{-a-1} \exp\{-b/\sigma^2\}. \end{aligned}$$

Termos destacados em vermelho são constantes (não dependem de  $\sigma^2$ ). Eles serão incorporados na constante normalizadora.

$$\begin{aligned} &\propto (\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2}(\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2)\right\} (\sigma^2)^{-a-1} \exp\{-b/\sigma^2\}. \\ &\propto (\sigma^2)^{-(a+n/2)-1} \exp\left\{-\frac{1}{\sigma^2}[b + \frac{1}{2}(\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2)]\right\}. \end{aligned}$$

Temos aqui o núcleo da distribuição  $\text{GI}(a^*, b^*)$ , com:

- O trecho em vermelho fornece:  $a^* = a + n/2$ .
- O trecho em verde estabelece:  $b^* = b + \frac{1}{2}(\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2)$ .

Conclusão: a distribuição *a priori*  $\sigma^2 \sim \text{GI}(a, b)$  e *a posteriori*  $\sigma^2|\mathbf{Y} \sim \text{GI}(a^*, b^*)$  são da família Gama Inversa.

Estudo simulado usando o modelo  $N(\mu, \sigma^2)$  com  $\mu$  conhecido:

Gerando dados artificiais (comandos R):

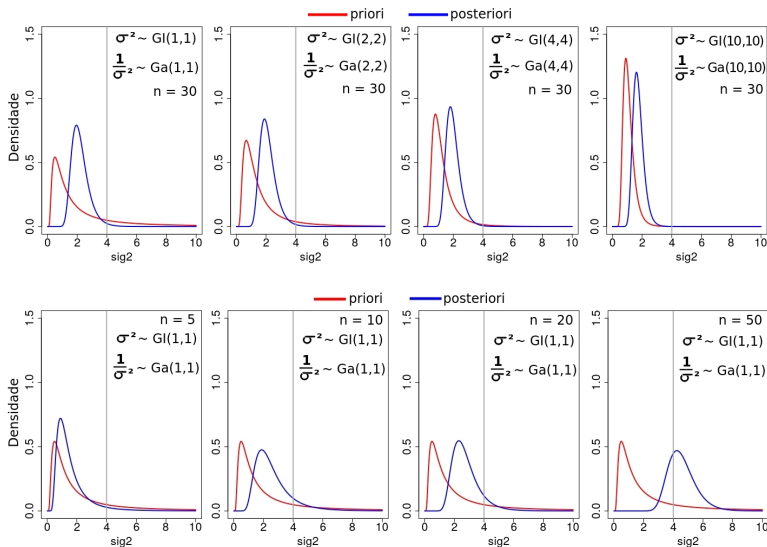
```
mureal = 5                # defina o verdadeiro valor de mu;
sig2real = 4              # defina o verdadeiro valor de sigma2;
n = 30                   # defina o tamanho amostral;
y = rnorm(n, mureal, sqrt(sig2real)) # gere observações da Normal.
```

Na prática,  $\sigma_{\text{real}}^2$  é desconhecido. Neste problema, o pesquisador teria acesso apenas à amostra  $\mathbf{y}$  e ao valor  $\mu_{\text{real}} = 5$ .

Os gráficos a seguir mostram a distribuição *a posteriori* perante diferentes especificações *a priori* e diferentes valores de  $n$ .

Comandos para cálculo da f.d.p. *a priori* e *a posteriori*:

```
dGI = function(x,a,b){ x^{-a-1} * exp(-b/x) * (b^a)/gamma(a) }
sig2 = seq(0.01, 10, 0.01)
prior = dGI(sig2, a, b)
as = a + n/2
bs = b + 0.5*(sum(y^2) -2*mureal*sum(y) + n*mureal^2)
post = dGI(sig2, as, bs)
```



## Comentários sobre os gráficos no slide anterior:

- Todas as especificações *a priori* indicam  $E(1/\sigma^2) = a/b = 1$  (lembre-se que  $1/\sigma_{\text{real}}^2 = 1/4$ , i.e., *priori equivocada*).
- $a = b$  aumentando  $\Rightarrow \text{Var}(1/\sigma^2) = a/b^2$  diminuindo.
- $1/\sigma^2 \sim \text{Ga}(10, 10) \Rightarrow \text{Var}(1/\sigma^2)$  pequena e  $E(1/\sigma^2) = 1 \neq 1/4$ ; f.d.p. *a posteriori* é muito influenciada e desloca para a esquerda.
- Para  $n = 30$ , a verossimilhança não teve força suficiente para dominar a informação *a priori*; f.d.p. *a posteriori* (azul) tem massa de probabilidade longe de  $\sigma_{\text{real}}^2 = 4$ .
- $n = 5$  determina uma f.d.p. *a posteriori* bastante afetada pela informação inicial equivocada.
- $n = 50$  determina uma f.d.p. *a posteriori* que concentra-se ao redor de  $\sigma_{\text{real}}^2 = 4$ .

Exercício: Use o R para simular e construir este tipo de gráfico. Assuma  $\mu_{\text{real}} = 5$ ,  $\sigma_{\text{real}}^2 = 4$ ,  $n = 30$  e a distribuição *a priori*  $\sigma^2 \sim \text{GI}(2.1, 1.1)$ . Calcule a esperança e a variância das distribuições *a priori* e *a posteriori* de  $\sigma^2$ .

## Reparametrizando a distribuição Normal para trabalhar com a precisão:

**Definição:** Se  $\sigma^2$  é um parâmetro de variância, dizemos que sua inversa (dada por  $\phi = 1/\sigma^2$ ) é um parâmetro de precisão. Quanto maior for o valor da variância  $\sigma^2$ , menor será o valor da precisão  $\phi$  (e vice versa). Visto que  $\sigma^2 > 0$ , temos  $\phi > 0$ .

Considere a variável aleatória  $Y_i|\mu, \sigma^2 \sim N(\mu, \sigma^2)$ . Podemos reformular sua f.d.p. para expressá-la em termos da precisão  $\phi = 1/\sigma^2$ . Isso é feito com segue:

$$f_{Y_i|\mu, \sigma^2}(y_i) = (2\pi\sigma^2)^{-1/2} \exp\left\{-\frac{1}{2\sigma^2}(y_i - \mu)^2\right\}.$$

$$\begin{aligned} f_{Y_i|\mu, \phi}(y_i) &= [2\pi(1/\phi)]^{-1/2} \exp\left\{-\frac{1}{2(1/\phi)}(y_i - \mu)^2\right\}. \\ &= (2\pi/\phi)^{-1/2} \exp\left\{-\frac{\phi}{2}(y_i - \mu)^2\right\} \quad \text{para } y_i \in \mathbb{R}. \end{aligned}$$

Tomando como base a reparametrização acima, o próximo slide volta a discutir a família conjugada para o modelo Normal com média conhecida.

**Distribuição  $N(\mu, 1/\phi)$  com média conhecida:** A família de distribuições Gama é conjugada com o modelo Normal para estimar a precisão  $\phi$ .

Assuma que  $\mathbf{Y} = \{Y_1, Y_2, \dots, Y_n\}$  é amostra aleatória da  $N(\mu, \sigma^2)$ . Admita independência condicional dos  $Y_i$ 's dado  $\sigma^2 = 1/\phi$ .

Espaço paramétrico:  $\phi \in \mathbb{R}^+$ .

Verossimilhança:  $f_{\mathbf{Y}|\phi}(\mathbf{y}) = \prod_{i=1}^n (2\pi/\phi)^{-1/2} \exp\{-\frac{\phi}{2}(y_i - \mu)^2\}$ .

$$= \prod_{i=1}^n (2\pi/\phi)^{-1/2} \exp\{-\frac{\phi}{2}(y_i^2 - 2\mu y_i + \mu^2)\}.$$

$$= (2\pi)^{-n/2} (\phi)^{n/2} \exp\{-\frac{\phi}{2}(\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2)\}.$$

Distribuição *a priori*:  $\phi \sim \text{Ga}(a, b)$ .



Distribuição *a posteriori*:  $f_{\phi|\mathbf{Y}}(\phi|\mathbf{y}) \propto f_{\mathbf{Y}|\phi}(\mathbf{y}) f_{\phi}(\phi)$

$$\propto (2\pi)^{-n/2} \phi^{n/2} \exp\left\{-\frac{\phi}{2}(\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2)\right\} \times \\ \times \frac{b^a}{\Gamma(a)} \phi^{a-1} \exp\{-b\phi\}.$$

Termos em vermelho são constantes (não dependem de  $\phi$ ). Eles serão incorporados na constante normalizadora.

$$f_{\phi|\mathbf{Y}}(\phi|\mathbf{y}) \propto \phi^{n/2} \exp\left\{-\frac{\phi}{2}(\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2)\right\} \phi^{a-1} \exp\{-b\phi\}. \\ \propto \phi^{(a+n/2)-1} \exp\left\{-\phi\left[b + \frac{1}{2}(\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2)\right]\right\}.$$

Temos aqui o núcleo da distribuição  $\text{Ga}(a^*, b^*)$ , com:

- O trecho em vermelho fornece:  $a^* = a + n/2$ .
- O trecho em verde estabelece:  $b^* = b + \frac{1}{2}(\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2)$ .

Conclusão: a distribuição *a priori*  $\phi \sim \text{Ga}(a, b)$  e a *posteriori*  $\phi | \mathbf{Y} \sim \text{Ga}(a^*, b^*)$  são da família Gama.

Note que não era necessário ter feito todas estas últimas contas para obter a distribuição *a posteriori* no caso reparametrizado com  $\phi$ .

Bastava ter percebido que:

se  $\sigma^2 | \mathbf{Y} \sim \text{GI}(a^*, b^*)$ , então  $(\sigma^2)^{-1} | \mathbf{Y} = \phi | \mathbf{Y} \sim \text{Ga}(a^*, b^*)$ .

As expressões de  $a^*$  e  $b^*$  são as mesmas com ou sem reparametrização.

**Definição:** Considere um par de variáveis aleatórias  $(X_1, X_2)$  e assuma que  $X_1|X_2 \sim N(m, v/X_2)$ , significando uma distribuição Normal com média  $m$  e variância  $v/X_2$ .

Suponha também que  $X_2 \sim \text{Ga}(a, b)$ .

Dizemos, neste caso, que  $(X_1, X_2) \sim \text{Normal-Gama}(m, v, a, b)$ , com  $m \in \mathbb{R}$ ,  $v > 0$ ,  $a > 0$  e  $b > 0$ , e sua f.d.p.  $f_{X_1, X_2}(x_1, x_2)$  é dada por:

$$\frac{b^a}{\Gamma(a)} (2\pi v)^{-1/2} x_2^{a-1/2} \exp\{-bx_2\} \exp\left\{-\frac{1}{2v}(x_1 - m)^2\right\} \text{ para } x_1 \in \mathbb{R} \text{ e } x_2 \in \mathbb{R}^+.$$

Neste contexto,  $E(X_1) = m$ ,  $E(X_2) = a/b$ ,  $\text{Var}(X_1) = \frac{bv}{a-1}$  e  $\text{Var}(X_2) = a/b^2$ .

A Normal-Gama é uma família bivariada de distribuições contínuas contendo 4 parâmetros  $(m, v, a, b)$ .

Esta distribuição será utilizada no próximo tópico.

**Distribuição  $N(\mu, 1/\phi)$  com média e variância desconhecidas:** A família Normal-Gama é conjugada com o modelo Normal para estimar o par  $(\mu, \phi)$ .

Considere  $\mathbf{Y} = \{Y_1, Y_2, \dots, Y_n\}$  uma amostra aleatória da  $N(\mu, 1/\phi)$  com os dois parâmetros desconhecidos. Admita independência condicional entre os  $Y_i$ 's dado  $(\mu, \phi)$ .

Espaço paramétrico:  $\mu \in \mathbb{R}$  e  $\phi \in \mathbb{R}^+$ .

Verossimilhança:  $f_{\mathbf{Y}|\mu,\phi}(\mathbf{y}) = \prod_{i=1}^n (2\pi/\phi)^{-1/2} \exp\{-\frac{\phi}{2}(y_i - \mu)^2\}$ .

$$= (2\pi)^{-n/2} \phi^{n/2} \exp\{-\frac{\phi}{2}(\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2)\}.$$

Distribuição *a priori*:  $f_{\mu,\phi}(\mu, \phi) = f_{\mu|\phi}(\mu) f_{\phi}(\phi)$ .

Este é um modelo bi-paramétrico, então a distribuição *a priori* a ser escolhida é uma distribuição conjunta conforme escrito acima.

Adote:  $\mu|\phi \sim N(m, v/\phi)$  e  $\phi \sim \text{Ga}(a, b)$ .

Veja que esta escolha significa:  $(\mu, \phi) \sim \text{Normal-Gama}(m, v, a, b)$ .





Importante: esta especificação conjunta não estabelece independência entre  $\mu$  e  $\phi$ .

$$f_{\mu, \phi}(\mu, \phi) = (2\pi v/\phi)^{-1/2} \exp\left\{-\frac{\phi}{2v}(\mu - m)^2\right\} \frac{b^a}{\Gamma(a)} \phi^{a-1} \exp\{-b\phi\}.$$

Distribuição *a posteriori*:  $f_{\mu, \phi|\mathbf{Y}}(\mu, \phi|\mathbf{y}) \propto f_{\mathbf{Y}|\mu, \phi}(\mathbf{y}) f_{\mu, \phi}(\mu, \phi)$

$$\propto (2\pi)^{-n/2} \phi^{n/2} \exp\left\{-\frac{\phi}{2}\left(\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2\right)\right\} \times \\ \times (2\pi v)^{-1/2} \phi^{1/2} \exp\left\{-\frac{\phi}{2v}(\mu^2 - 2\mu m)\right\} \exp\left\{-\frac{\phi}{2v}m^2\right\} \frac{b^a}{\Gamma(a)} \phi^{a-1} \exp\{-b\phi\}.$$

Termos em vermelho são constantes (não dependem de  $\mu$  ou  $\phi$ ). Eles serão incorporados na constante normalizadora.



A estratégia para continuar a conta é separar a expressão em duas partes conforme estabelece a seguinte fatoração da f.d.p. conjunta *a posteriori*:

$$f_{\mu, \phi | \mathbf{Y}}(\mu, \phi | \mathbf{y}) = f_{\mu | \phi, \mathbf{Y}}(\mu | \mathbf{y}) f_{\phi | \mathbf{Y}}(\phi).$$

- Parte vermelha: depende de  $\mu$  e pode conter  $\phi$ .
- Parte verde: depende apenas de  $\phi$ .

Diante desta visão, aplica-se a seguinte separação:

$$\begin{aligned} f_{\mu, \phi | \mathbf{Y}}(\mu, \phi | \mathbf{y}) &\propto \phi^{1/2} \exp\left\{-\frac{\phi}{2}(-2\mu \sum_{i=1}^n y_i + n\mu^2)\right\} \exp\left\{-\frac{\phi}{2v}(\mu^2 - 2\mu m)\right\} \times \\ &\quad \times \phi^{n/2} \exp\left\{-\frac{\phi}{2}(\sum_{i=1}^n y_i^2)\right\} \exp\left\{-\frac{\phi}{2v}m^2\right\} \phi^{a-1} \exp\{-b\phi\}. \\ &\propto \phi^{1/2} \exp\left\{-\frac{1}{2}[-2\mu\phi \sum_{i=1}^n y_i + n\phi\mu^2 + \frac{\phi}{v}\mu^2 - 2\mu\frac{\phi m}{v}]\right\} \times \\ &\quad \times \phi^{a+n/2-1} \exp\left\{-\phi\left[b + \frac{\sum_{i=1}^n y_i^2}{2} + \frac{m^2}{2v}\right]\right\}. \end{aligned}$$

$$f_{\mu, \phi | \mathbf{Y}}(\mu, \phi | \mathbf{y}) \propto \phi^{1/2} \exp\left\{-\frac{1}{2}\left[\mu^2\left(n\phi + \frac{\phi}{v}\right) - 2\mu\left(\phi \sum_{i=1}^n y_i + \frac{\phi m}{v}\right)\right]\right\} \times \\ \times \phi^{a+n/2-1} \exp\left\{-\phi\left[b + \frac{\sum_{i=1}^n y_i^2}{2} + \frac{m^2}{2v}\right]\right\}.$$

$$\propto \phi^{1/2} \exp\left\{-\frac{1}{2}\left(n + \frac{1}{v}\right)\phi\left[\mu^2 - 2\mu\left(n + \frac{1}{v}\right)^{-1}\left(\sum_{i=1}^n y_i + \frac{m}{v}\right)\right]\right\} \times \\ \times \phi^{a+n/2-1} \exp\left\{-\phi\left[b + \frac{\sum_{i=1}^n y_i^2}{2} + \frac{m^2}{2v}\right]\right\}.$$

Simplificando a notação, denote:

$$v^* = \left(n + \frac{1}{v}\right)^{-1} \quad \text{e} \quad m^* = v^*\left(\sum_{i=1}^n y_i + \frac{m}{v}\right).$$

Então:

$$f_{\mu, \phi | \mathbf{Y}}(\mu, \phi | \mathbf{y}) \propto \phi^{1/2} \exp\left\{-\frac{\phi}{2v^*}\left[\mu^2 - 2\mu m^* + (m^*)^2 - (m^*)^2\right]\right\} \times \\ \times \phi^{a+n/2-1} \exp\left\{-\phi\left[b + \frac{\sum_{i=1}^n y_i^2}{2} + \frac{m^2}{2v}\right]\right\}.$$



$$f_{\mu, \phi | \mathbf{y}}(\mu, \phi | \mathbf{y}) \propto \phi^{1/2} \exp\left\{-\frac{\phi}{2\nu^*} [\mu^2 - 2\mu m^* + (m^*)^2]\right\} \exp\left\{+\frac{\phi}{2\nu^*} (m^*)^2\right\} \times \\ \times \phi^{a+n/2-1} \exp\left\{-\phi\left[b + \frac{\sum_{i=1}^n y_i^2}{2} + \frac{m^2}{2\nu}\right]\right\}.$$

$$\propto \phi^{1/2} \exp\left\{-\frac{\phi}{2\nu^*} (\mu - m^*)^2\right\} \times \\ \times \phi^{a+n/2-1} \exp\left\{-\phi\left[b + \frac{\sum_{i=1}^n y_i^2}{2} + \frac{m^2}{2\nu}\right]\right\} \exp\left\{+\frac{\phi}{2\nu^*} (m^*)^2\right\}.$$

$$\propto \phi^{1/2} \exp\left\{-\frac{\phi}{2\nu^*} (\mu - m^*)^2\right\} \phi^{a+n/2-1} \exp\left\{-\phi\left[b + \frac{\sum_{i=1}^n y_i^2}{2} + \frac{m^2}{2\nu} - \frac{(m^*)^2}{2\nu^*}\right]\right\}.$$

Novamente simplificando a notação denote:

$$a^* = a + n/2 \quad \text{e} \quad b^* = b + \frac{\sum_{i=1}^n y_i^2}{2} + \frac{m^2}{2\nu} - \frac{(m^*)^2}{2\nu^*}.$$

$$f_{\mu, \phi | \mathbf{y}}(\mu, \phi | \mathbf{y}) = (2\pi\nu^*)^{-1/2} \phi^{1/2} \exp\left\{-\frac{\phi}{2\nu^*} (\mu - m^*)^2\right\} \times \\ \times \frac{(b^*)^{a^*}}{\Gamma(a^*)} \phi^{a^*-1} \exp\{-\phi b^*\}.$$

Os termos adicionados em preto são constantes (não dependem de  $\mu$  ou  $\phi$ ).

Logo  $(\mu, \phi) | \mathbf{Y} \sim \text{Normal-Gama}(m^*, v^*, a^*, b^*)$  com

$$v^* = (n + \frac{1}{v})^{-1}, \quad m^* = v^* (\sum_{i=1}^n y_i + \frac{m}{v}),$$

$$a^* = a + n/2 \quad \text{e} \quad b^* = b + \frac{\sum_{i=1}^n y_i^2}{2} + \frac{m^2}{2v} - \frac{(m^*)^2}{2v^*}.$$

Conclusão: as distribuições *a priori*  $(\mu, \phi) \sim \text{Normal-Gama}(m, v, a, b)$  e *a posteriori*  $(\mu, \phi) | \mathbf{Y} \sim \text{Normal-Gama}(m^*, v^*, a^*, b^*)$  são da família Normal-Gama.

Ressalta-se novamente que assumir  $(\mu, \phi) \sim \text{Normal-Gama}$  *a priori* estabelece uma dependência entre estes parâmetros.

Pergunta: Como fica a análise Bayesiana para o caso Normal com  $\mu$  e  $\phi$  desconhecidos sob a suposição de independência *a priori* entre  $\mu$  e  $\phi$ ?

A implicação desta suposição é que  $f_{\mu, \phi}(\mu, \phi) = f_{\mu}(\mu) f_{\phi}(\phi)$ .

Adote  $\mu \sim N(m, v)$  e  $\phi \sim \text{Ga}(a, b)$ .

$$f_{\mu,\phi}(\mu, \phi) = (2\pi\nu)^{-1/2} \exp\left\{-\frac{1}{2\nu}(\mu - m)^2\right\} \frac{b^a}{\Gamma(a)} \phi^{a-1} \exp\{-b\phi\}.$$

Distribuição *a posteriori*:  $f_{\mu,\phi|\mathbf{Y}}(\mu, \phi|\mathbf{y}) \propto f_{\mathbf{Y}|\mu,\phi}(\mathbf{y}) f_{\mu,\phi}(\mu, \phi)$

$$\propto (2\pi)^{-n/2} \phi^{n/2} \exp\left\{-\frac{\phi}{2}(\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2)\right\} \times \\ \times (2\pi\nu)^{-1/2} \exp\left\{-\frac{1}{2\nu}(\mu^2 - 2\mu m)\right\} \exp\left\{-\frac{1}{2\nu}m^2\right\} \frac{b^a}{\Gamma(a)} \phi^{a-1} \exp\{-b\phi\}.$$

Termos em vermelho são constantes (não dependem de  $\mu$  ou  $\phi$ ). Eles serão incorporados na constante normalizadora.

Fatoração da f.d.p. conjunta *a posteriori*:

$$f_{\mu,\phi|\mathbf{Y}}(\mu, \phi|\mathbf{y}) = f_{\mu|\phi,\mathbf{Y}}(\mu|\mathbf{y}) f_{\phi|\mathbf{Y}}(\phi).$$

- Parte vermelha: depende de  $\mu$  e pode conter  $\phi$ .
- Parte verde: depende apenas de  $\phi$ .

$$f_{\mu, \phi | \mathbf{Y}}(\mu, \phi | \mathbf{y}) \propto \exp\left\{-\frac{\phi}{2}(-2\mu \sum_{i=1}^n y_i + n\mu^2)\right\} \exp\left\{-\frac{1}{2v}(\mu^2 - 2\mu m)\right\} \times \\ \times \phi^{n/2} \exp\left\{-\frac{\phi}{2}(\sum_{i=1}^n y_i^2)\right\} \phi^{a-1} \exp\{-b\phi\}.$$

$$\propto \exp\left\{-\frac{1}{2}(-2\mu\phi \sum_{i=1}^n y_i + n\phi\mu^2 + \frac{1}{v}\mu^2 - 2\mu\frac{m}{v})\right\} \times \\ \times \phi^{a+n/2-1} \exp\left\{-\phi\left[b + \frac{\sum_{i=1}^n y_i^2}{2}\right]\right\}.$$

$$\propto \exp\left\{-\frac{1}{2}[\mu^2(n\phi + \frac{1}{v}) - 2\mu(\phi \sum_{i=1}^n y_i + \frac{m}{v})]\right\} \times \\ \times \phi^{a+n/2-1} \exp\left\{-\phi\left[b + \frac{\sum_{i=1}^n y_i^2}{2}\right]\right\}.$$

$$\propto \exp\left\{-\frac{1}{2}(n\phi + \frac{1}{v}) [\mu^2 - 2\mu (\phi \sum_{i=1}^n y_i + \frac{m}{v})]\right\} \times \\ \times \phi^{a+n/2-1} \exp\left\{-\phi\left[b + \frac{\sum_{i=1}^n y_i^2}{2}\right]\right\}.$$

Denote:  $v_{\phi}^* = (n\phi + \frac{1}{v})^{-1}$ ,  $m_{\phi}^* = v_{\phi}^* (\phi \sum_{i=1}^n y_i + \frac{m}{v})$ ,

$\tilde{a} = a + n/2$  e  $\tilde{b} = b + \sum_{i=1}^n y_i^2/2$ .

O subscrito “ $\phi$ ” foi usado para lembrar que as expressões dependem de  $\phi$ .

$$\begin{aligned}
f_{\mu, \phi | \mathbf{y}}(\mu, \phi | \mathbf{y}) &\propto \exp\left\{-\frac{1}{2v_\phi^*} [\mu^2 - 2\mu m_\phi^* + (m_\phi^*)^2 - (m_\phi^*)^2]\right\} \times \\
&\times \phi^{\tilde{a}-1} \exp\{-\phi \tilde{b}\}. \\
&\propto \exp\left\{-\frac{1}{2v_\phi^*} [\mu^2 - 2\mu m_\phi^* + (m_\phi^*)^2]\right\} \exp\left\{+\frac{(m_\phi^*)^2}{2v_\phi^*}\right\} \times \phi^{\tilde{a}-1} \exp\{-\phi \tilde{b}\}. \\
&\propto (v_\phi^*)^{-1/2} \exp\left\{-\frac{1}{2v_\phi^*} (\mu - m_\phi^*)^2\right\} \times (v_\phi^*)^{1/2} \exp\left\{+\frac{(m_\phi^*)^2}{2v_\phi^*}\right\} \times \phi^{\tilde{a}-1} \exp\{-\phi \tilde{b}\}.
\end{aligned}$$

O termo **vermelho** é o núcleo de uma Normal. Já o termo **verde** é o núcleo de uma Gama. Perceba que o termo central (em **preto**) depende de  $\phi$  e, portanto, não pode ser incorporado na constante normalizadora. Além disso, ele não pode ser combinado com o termo **vermelho** ou **verde** para formar uma distribuição de probabilidade conhecida.

Conclusão: Não haverá conjugação quando assumimos independência *a priori* para  $(\mu, \phi)$ . Usar a suposição de independência nos coloca em uma situação em que não sabemos identificar a distribuição *a posteriori* conjunta  $f_{\mu, \phi | \mathbf{y}}(\mu, \phi | \mathbf{y})$ .

Voltaremos a este problema mais adiante no curso.

**Distribuição Multinomial:** A família Dirichlet é conjugada com o modelo Multinomial para estimar o vetor de probabilidades  $\theta = \{\theta_1, \theta_2, \dots, \theta_q\}$ .

Suponha que  $\mathbf{Y} = \{Y_1, Y_2, \dots, Y_n\}$  é uma amostra aleatória de tamanho  $n$  relativa a um experimento em que  $Y_i$  indica em qual categoria, de  $q$  possíveis, o elemento  $i$  faz parte. Podemos escrever que  $Y_i = j$  se o  $i$ -ésimo experimento resultou na categoria  $j \in \{1, 2, \dots, q\}$ .

Seja  $W = \{W_1, W_2, \dots, W_q\}$  um conjunto de variáveis aleatórias, tal que  $W_j = \sum_{i=1}^n 1_{\{Y_i=j\}}$  é o número de experimentos que indicaram categoria  $j$ . Admita que  $\theta_j$  é a probabilidade de um elemento qualquer ser classificado na categoria  $j$ . Notação:  $\theta = \{\theta_1, \theta_2, \dots, \theta_q\}$ .

Importante:  $\sum_{j=1}^q W_j = n$  e  $\sum_{j=1}^q \theta_j = 1$ .

Dizemos que  $W$  tem distribuição Multinomial( $n, \theta$ ) com a seguinte f.m.p.

$$f_{W|\theta}(w) = \frac{n!}{\prod_{j=1}^q w_j!} \prod_{j=1}^q \theta_j^{w_j} \quad \text{para } \theta_j \in [0, 1], \quad w_j \in \{0, 1, 2, \dots, n\}.$$

Exemplo: Um dado de 6 faces ( $q = 6$  categorias) é lançado  $n = 100$  vezes. Neste caso,  $Y_i = j$  se o  $i$ -ésimo lançamento indicou a face  $j \in \{1, 2, 3, 4, 5, 6\}$ .

Uma observação do vetor aleatório  $W = \{W_1, W_2, W_3, W_4, W_5, W_6\}$  indica o número de vezes que cada face ocorreu.

É natural, neste contexto, supor que  $\theta_j = 1/6$  para todo  $j$ .

Considere a simulação abaixo usando comandos do R.

```
# Simulando os 100 lançamentos do dado.  
y = sample(1:6, 100, replace = TRUE, prob = rep(1/6,6))  
  
# Contando o número de ocorrência de cada face.  
w = table(y)  
  
  1    2    3    4    5    6  
16  15  18  17  18  16  
  
sum(w) # resulta em 100
```

Lembrete: A distribuição Beta é sempre atribuída para variáveis aleatórias contínuas limitadas no intervalo  $[0, 1]$ . Conforme visto anteriormente, ela é uma opção adequada como distribuição *a priori* para a desconhecida probabilidade de sucesso  $\theta_1$ , em um experimento do tipo sucesso e fracasso.

A probabilidade de fracasso seria denotada por  $(1 - \theta_1) = \theta_2$ .

Veja que:  $\theta = \{\theta_1, \theta_2\}$  é um par de probabilidades tal que  $\theta_1 + \theta_2 = 1$ .

A distribuição Dirichlet é uma generalização da distribuição Beta, servindo para descrever o comportamento de um vetor de probabilidades  $\theta = \{\theta_1, \theta_2, \dots, \theta_q\}$  com dimensão  $q > 2$  e satisfazendo  $\sum_{j=1}^q \theta_j = 1$ .

**Definição:** Se  $\theta$  segue a distribuição **Dirichlet** com vetor paramétrico  $a = (a_1, \dots, a_q)^\top$ , tal que  $a_i > 0$  e  $\sum_{i=1}^q a_i = \alpha$ , então sua f.d.p. será:

$$f_{\theta}(\theta) = \frac{\Gamma(\alpha)}{\prod_{j=1}^q \Gamma(a_j)} \prod_{j=1}^q \theta_j^{a_j-1} \quad \text{para } \theta_j \in [0, 1] \text{ e } \sum_{j=1}^q \theta_j = 1.$$

$\alpha$  é geralmente chamado de parâmetro de concentração.



A família Dirichlet com parâmetros inteiros  $a = (a_1, \dots, a_q)^\top$ , notação  $\text{Dir}(a)$ , é conjugada natural com o modelo multinomial.

Novamente, pouco perdemos ao estender a conjugação natural considerando todas as distribuições Dirichlet, ou seja, sem a restrição de  $a = (a_1, \dots, a_q)^\top$  contendo apenas inteiros.

Verossimilhança Multinomial:  $f_{W|\theta}(w) = \frac{n!}{\prod_{j=1}^q w_j!} \prod_{j=1}^q \theta_j^{w_j}$ .

Distribuição *a priori*  $\text{Dir}(a)$ :  $f_\theta(\theta) = \frac{\Gamma(\alpha)}{\prod_{j=1}^q \Gamma(a_j)} \prod_{j=1}^q \theta_j^{a_j-1}$

Os trechos destacados em verde são os núcleos (parte que depende do parâmetro alvo  $\theta$ ). Perceba a semelhança entre eles.

Esta semelhança é ponto chave para obter a conjugação.

Distribuição *a posteriori*:

$$f_{\theta|W}(\theta|w) \propto f_{W|\theta}(w) f_{\theta}(\theta) \propto \frac{n!}{\prod_{j=1}^q w_j!} \prod_{j=1}^q \theta_j^{w_j} \frac{\Gamma(\alpha)}{\prod_{j=1}^q \Gamma(a_j)} \prod_{j=1}^q \theta_j^{a_j-1}$$

Trechos vermelhos são constantes (não dependem de  $\theta$ ) que serão incorporadas à constante de normalização.

$$f_{\theta|W}(\theta|w) \propto \prod_{j=1}^q \theta_j^{w_j} \prod_{j=1}^q \theta_j^{a_j-1} \propto \prod_{j=1}^q \theta_j^{a_j+w_j-1}.$$

Este é o núcleo da Dirichlet com parâmetro  $a^* = (a_1 + w_1, a_2 + w_2, \dots, a_q + w_q)$ .

$$f_{\theta|W}(\theta|w) = \frac{\Gamma(\alpha + n)}{\prod_{j=1}^q \Gamma(a_j + w_j)} \prod_{j=1}^q \theta_j^{a_j+w_j-1}. \quad \text{Denota-se } \theta|w \sim \text{Dir}(a^*).$$

Conclusão: as distribuições *a priori*  $\theta \sim \text{Dir}(a)$  e *a posteriori*  $\theta|W \sim \text{Dir}(a^*)$  são da família Dirichlet.

## Conjugação na família exponencial.

**Definição:** A família exponencial é formada pelas funções (f.d.p. ou f.m.p.) que podem ser escritas na seguinte configuração

$$f_{Y|\theta}(y) = s(y) t(\theta) \exp\{a(y) b(\theta)\},$$

em que  $s(\bullet)$  e  $t(\bullet)$  são funções que assumem valores em  $\mathbb{R}^+$ .

Ademais  $a(\bullet)$  e  $b(\bullet)$  são funções vetoriais de dimensão  $K$ .

Esta expressão pode ser rescrita como:

$$f_{Y|\theta}(y) = \exp\{a(y) b(\theta) + c(\theta) + d(y)\},$$

sendo  $c(\theta) = \ln[t(\theta)]$  e  $d(y) = \ln[s(y)]$ .

Resultado de inferência: Pelo teorema da fatoração de Neyman, o termo  $a(y)$  é uma estatística suficiente para  $\theta$ .

Várias distribuições conhecidas fazem parte da família exponencial, tais como: Poisson, Binomial, Binomial Negativa, Rayleigh, Exponencial, Gama, Normal e Normal Inversa (citando apenas algumas).

O suporte  $\{y; f_{Y|\theta}(y) > 0\}$  de uma distribuição membro da família exponencial não pode depender de  $\theta$ . Assim, por exemplo, a distribuição  $U(0, \theta)$  não é membro desta família, pois não podemos identificar  $a(y)$  e  $b(\theta)$  através da f.d.p.:

$$f_{Y|\theta}(y) = \frac{1}{\theta} 1_{\{0 < y < \theta\}} \quad \text{em que } 1_{\{\bullet\}} \text{ é função indicadora.}$$

Mostrar que uma distribuição faz parte da família exponencial não é difícil. Veja três exemplos a seguir.

Exemplo: Considere uma variável aleatória discreta com distribuição Poisson; ou seja,  $Y \sim \text{Poisson}(\theta)$  com  $\theta > 0$ . Sua f.m.p. é dada por

$$f_{Y|\theta}(y) = \frac{\theta^y}{y!} \exp\{-\theta\} = \frac{1}{y!} e^{-\theta} \exp\{y \ln(\theta)\} \text{ para } y = 0, 1, 2, \dots$$

Note que:  $s(y) = 1/y!$ ,  $t(\theta) = e^{-\theta}$ ,  $a(y) = y$  e  $b(\theta) = \ln(\theta)$ .

Veja que  $a(y)$  e  $b(\theta)$  são escalares ( $K = 1$ ) neste caso.

Exemplo: Seja  $Y \sim \text{Binomial}(m, \theta)$  com  $0 < \theta < 1$  e  $m = n^\circ$  conhecido de ensaios Bernoulli independentes. A f.m.p. é como segue

$$f_{Y|\theta}(y) = \binom{m}{y} \theta^y (1 - \theta)^{m-y} = \binom{m}{y} (1 - \theta)^m \exp\left\{y \ln\left(\frac{\theta}{1 - \theta}\right)\right\} \text{ para } y = 0, 1, \dots, m.$$

Temos aqui:  $s(y) = \binom{m}{y}$ ,  $t(\theta) = (1 - \theta)^m$ ,  $a(y) = y$  e  $b(\theta) = \ln\left(\frac{\theta}{1 - \theta}\right)$ .  
Observe que  $a(y)$  e  $b(\theta)$  são escalares ( $K = 1$ ) neste caso.

Lembrete:  $\text{Binomial}(m = 1, \theta) = \text{Bernoulli}(\theta)$ .

Exemplo: Considere  $Y \sim N(\mu, \sigma^2)$  com  $\mu \in \mathbb{R}$  e  $\sigma^2 \in \mathbb{R}^+$ .  
Neste caso bi-paramétrico, denota-se  $\theta = \{\mu, \sigma^2\}$ .

$$\begin{aligned} f_{Y|\mu, \sigma^2}(y) &= (2\pi\sigma^2)^{-1/2} \exp\left\{-\frac{1}{2\sigma^2}(y - \mu)^2\right\} \quad \text{para } y \in \mathbb{R}, \\ &= (2\pi\sigma^2)^{-1/2} \exp\left\{-\frac{1}{2\sigma^2}(y^2 - 2y\mu + \mu^2)\right\}, \\ &= (2\pi\sigma^2)^{-1/2} \exp\left\{-\frac{y^2}{2\sigma^2} + \frac{y\mu}{\sigma^2} - \frac{\mu^2}{2\sigma^2}\right\}, \\ &= (2\pi)^{-1/2} (\sigma^2)^{-1/2} \exp\left\{-\frac{\mu^2}{2\sigma^2}\right\} \exp\left\{(y^2, y) \left(-\frac{1}{2\sigma^2}, \frac{\mu}{\sigma^2}\right)^\top\right\}. \end{aligned}$$

Temos:  $s(y) = (2\pi)^{-1/2}$ ,  $t(\theta) = (\sigma^2)^{-1/2} \exp\left\{-\frac{\mu^2}{2\sigma^2}\right\}$ ,

$a(y) = (y^2, y)$ ,  $b(\theta) = \left(-\frac{1}{2\sigma^2}, \frac{\mu}{\sigma^2}\right)^\top$ .

Perceba que  $a(y)$  e  $b(\theta)$  são vetores ( $K = 2$ ).

Considere  $\mathbf{Y} = \{Y_1, Y_2, \dots, Y_n\}$  uma amostra aleatória proveniente de uma distribuição membro da família exponencial. Esta distribuição é indexada pelo parâmetro  $\theta$  (escalar ou vetor) e existe independência condicional dos  $Y_i$ 's dado  $\theta$ .

Podemos escrever:  $f_{Y_i|\theta}(y_i) = s(y_i) t(\theta) \exp\{a(y_i) b(\theta)\}$ .

$$\begin{aligned}\text{Verossimilhança: } f_{\mathbf{Y}|\theta}(\mathbf{y}) &= \prod_{i=1}^n s(y_i) t(\theta) \exp\{a(y_i) b(\theta)\}. \\ &= \left[ \prod_{i=1}^n s(y_i) \right] t(\theta)^n \exp \left\{ \left[ \sum_{i=1}^n a(y_i) \right] b(\theta) \right\}.\end{aligned}$$

Distribuição *a priori* conjugada para  $\theta$ :

Note que o núcleo (parte atrelada a  $\theta$ ) da função de verossimilhança é

$$f_{\mathbf{Y}|\theta}(\mathbf{y}) \propto t(\theta)^n \exp \left\{ \left[ \sum_{i=1}^n a(y_i) \right] b(\theta) \right\}.$$

Visando obter uma especificação *a priori* semelhante a este núcleo, denote  $\alpha = n$  e  $\beta = \sum_{i=1}^n a(y_i)$ . A partir disso, escreva

$$f_{\theta}(\theta) \propto t(\theta)^{\alpha} \exp \{ \beta b(\theta) \}, \quad \text{ou seja} \quad f_{\theta}(\theta) = C_N t(\theta)^{\alpha} \exp \{ \beta b(\theta) \},$$

sendo  $1/C_N = \int_{\Theta} t(\theta)^{\alpha} \exp \{ \beta b(\theta) \} d\theta$ .

A distribuição *a posteriori*  $f_{\theta|\mathbf{Y}}(\theta|\mathbf{y})$  é obtida via Teorema de Bayes como segue:

$$\frac{\left[ \prod_{i=1}^n s(y_i) \right] t(\theta)^n \exp \left\{ \left[ \sum_{i=1}^n a(y_i) \right] b(\theta) \right\} C_N t(\theta)^\alpha \exp \{ \beta b(\theta) \}}{\int_{\Theta} \left[ \prod_{i=1}^n s(y_i) \right] t(\theta)^n \exp \left\{ \left[ \sum_{i=1}^n a(y_i) \right] b(\theta) \right\} C_N t(\theta)^\alpha \exp \{ \beta b(\theta) \} d\theta}.$$

Termos em vermelho são constantes (não dependem de  $\theta$ ) e irão cancelar.

$$f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) = \frac{t(\theta)^{\alpha+n} \exp \left\{ \left[ \sum_{i=1}^n a(y_i) \right] b(\theta) + \beta b(\theta) \right\}}{\int_{\Theta} t(\theta)^{\alpha+n} \exp \left\{ \left[ \sum_{i=1}^n a(y_i) \right] b(\theta) + \beta b(\theta) \right\} d\theta}$$

$$= \frac{t(\theta)^{\alpha+n} \exp \left\{ \left[ \beta + \sum_{i=1}^n a(y_i) \right] b(\theta) \right\}}{\int_{\Theta} t(\theta)^{\alpha+n} \exp \left\{ \left[ \beta + \sum_{i=1}^n a(y_i) \right] b(\theta) \right\} d\theta}$$

$$= C_N^* t(\theta)^{\alpha+n} \exp \left\{ \left[ \beta + \sum_{i=1}^n a(y_i) \right] b(\theta) \right\},$$

$$\text{sendo } 1/C_N^* = \int_{\Theta} t(\theta)^{\alpha+n} \exp \left\{ \left[ \beta + \sum_{i=1}^n a(y_i) \right] b(\theta) \right\} d\theta.$$



Para um modelo da família exponencial temos

- *a priori*:  $f_{\theta}(\theta) = C_N t(\theta)^{\alpha} \exp\{\beta b(\theta)\}.$
- *a posteriori*:  $f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) = C_N^* t(\theta)^{\alpha+n} \exp\{[\beta + \sum_{i=1}^n a(y_i)] b(\theta)\}$

As duas distribuições acima estão na mesma família, portanto, há conjugação.

Exemplo: Seja  $\mathbf{Y} = \{Y_1, Y_2, \dots, Y_n\}$  uma amostra aleatória da Bernoulli( $\theta$ ).

Sabe-se que esta distribuição é membro da família exponencial com:

$$s(y_i) = \binom{1}{y_i}, \quad t(\theta) = 1 - \theta, \quad a(y_i) = y_i \quad \text{e} \quad b(\theta) = \ln\left(\frac{\theta}{1-\theta}\right).$$

Reveja o exemplo com a Binomial alguns slides atrás.

$$\text{Verossimilhança: } f_{\mathbf{Y}|\theta}(\mathbf{y}) = \prod_{i=1}^n s(y_i) t(\theta) \exp\{a(y_i) b(\theta)\}$$

$$= \prod_{i=1}^n \binom{1}{y_i} (1 - \theta) \exp\left\{y_i \ln\left(\frac{\theta}{1-\theta}\right)\right\}$$

Distribuição *a priori* conjugada:  $f_{\theta}(\theta) \propto t(\theta)^{\alpha} \exp \{ \beta b(\theta) \}$

Usando  $t(\theta) = 1 - \theta$  e  $b(\theta) = \ln \left( \frac{\theta}{1-\theta} \right)$  teremos

$$f_{\theta}(\theta) \propto (1 - \theta)^{\alpha} \exp \left\{ \beta \ln \left( \frac{\theta}{1-\theta} \right) \right\} \propto (1 - \theta)^{\alpha} \exp \left\{ \ln \left( \frac{\theta}{1-\theta} \right)^{\beta} \right\}$$

$$\propto (1 - \theta)^{\alpha} \frac{\theta^{\beta}}{(1 - \theta)^{\beta}} \propto \theta^{\beta} (1 - \theta)^{\alpha - \beta}.$$

O núcleo acima indica que a distribuição  $\text{Beta}(\beta + 1, \alpha - \beta + 1)$  é a candidata para obter conjugação.

Distribuição *a posteriori*:

$$f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) \propto t(\theta)^{\alpha+n} \exp \left\{ \left[ \beta + \sum_{i=1}^n a(y_i) \right] b(\theta) \right\}, \quad \text{lembrete: } a(y_i) = y_i,$$
$$\propto (1 - \theta)^{\alpha+n} \exp \left\{ \left[ \beta + \sum_{i=1}^n y_i \right] \ln \left( \frac{\theta}{1-\theta} \right) \right\}$$

$$f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) \propto (1-\theta)^{\alpha+n} \exp \left\{ \ln \left( \frac{\theta}{1-\theta} \right)^{\beta+\sum_{i=1}^n y_i} \right\}$$

$$\propto (1-\theta)^{\alpha+n} \frac{\theta^{\beta+\sum_{i=1}^n y_i}}{(1-\theta)^{\beta+\sum_{i=1}^n y_i}} \propto \theta^{\beta+\sum_{i=1}^n y_i} (1-\theta)^{\alpha+n-\beta-\sum_{i=1}^n y_i}.$$

O resultado final é o núcleo da Beta(  $\beta + \sum_{i=1}^n y_i$  ,  $\alpha + n - \beta - \sum_{i=1}^n y_i$  ).

### Exercícios:

- Assim como foi feito nos slides para o modelo Bernoulli( $\theta$ ), escreva a distribuição *a priori* e *a posteriori* para os seguintes membros da família exponencial: (a) Poisson( $\theta$ ) e (b) Gama( $\lambda_1, \lambda_2$ ) com  $\theta = \{\lambda_1, \lambda_2\}$ .
- Determine a formulação da distribuição preditiva  $f_{\mathbf{Y}}(\mathbf{y})$  *a priori* para a família exponencial.

## Conjugação fora da família exponencial.

A conjugação não é uma propriedade exclusiva das distribuições da família exponencial. O caso discutido a seguir envolve a  $U(0, \theta)$ , que não pertence a essa família.

Seja  $\mathbf{Y} = \{Y_1, Y_2, \dots, Y_n\}$  uma amostra aleatória tal que  $Y_i|\theta \sim U(0, \theta)$  para  $\theta > 0$ . Adote independência condicional dos  $Y_i$ 's dado  $\theta$ .

$f_{Y_i|\theta}(y_i) = 1/\theta$  se  $y_i \in (0, \theta)$ . A f.d.p. será 0 caso contrário.

Esta expressão pode ser rescrita usando a função indicadora  $1_{\{0 < y_i < \theta\}}$ :

$$f_{Y_i|\theta}(y_i) = \frac{1}{\theta} 1_{\{0 < y_i < \theta\}}$$

$$\text{Verossimilhança: } f_{\mathbf{Y}|\theta}(\mathbf{y}) = \prod_{i=1}^n \frac{1}{\theta} 1_{\{0 < y_i < \theta\}} = \frac{1}{\theta^n} \prod_{i=1}^n 1_{\{0 < y_i < \theta\}}.$$

Perceba que  $\prod_{i=1}^n 1_{\{0 < y_i < \theta\}} = 1$ , se e somente se:

$$0 < y_1 < \theta \text{ e } 0 < y_2 < \theta \text{ e } 0 < y_3 < \theta \text{ e } \cdots \text{ e } 0 < y_n < \theta.$$

Denote  $y_{(n)} = \max\{y_1, y_2, \dots, y_n\}$  e veja que se  $y_{(n)} < \theta$  temos certamente que todos os  $y_i$ 's são menores que  $\theta$ .

Então  $\prod_{i=1}^n 1_{\{0 < y_i < \theta\}} = 1$  ocorre quando  $1_{\{y_{(n)} < \theta\}} = 1_{\{\theta > y_{(n)}\}} = 1$ .


Isso permite escrever:  $f_{\mathbf{Y}|\theta}(\mathbf{y}) = \frac{1}{\theta^n} 1_{\{\theta > y_{(n)}\}}$

**Definição:** Uma variável aleatória contínua  $X$  com distribuição Pareto( $a, b$ ),  $a > 0$  é parâmetro de escala e  $b > 0$  é parâmetro de forma, tem a seguinte f.d.p.

$$f_X(x) = \frac{b a^b}{x^{b+1}} 1_{\{x > a\}}.$$

Note a semelhança com o núcleo da verossimilhança se adotarmos *a priori*

$$\theta \sim \text{Pareto}(a, b) \text{ com f.d.p. } f_{\theta}(\theta) = \frac{b a^b}{\theta^{b+1}} 1_{\{\theta > a\}}.$$



Distribuição *a posteriori*:  $f_{\theta|\mathbf{Y}}(\theta|\mathbf{y}) \propto \frac{1}{\theta^n} \mathbf{1}_{\{\theta > y_{(n)}\}} \frac{b}{\theta^{b+1}} a^b \mathbf{1}_{\{\theta > a\}}.$

Termos em vermelho são constantes (não dependem de  $\theta$ ) e serão incorporadas na constante de normalização.

$$\propto \frac{1}{\theta^{n+b+1}} \mathbf{1}_{\{\theta > y_{(n)}\}} \mathbf{1}_{\{\theta > a\}} \propto \frac{1}{\theta^{n+b+1}} \mathbf{1}_{\{\theta > \max\{y_1, \dots, y_n, a\}\}}.$$

Este é o núcleo da  $\text{Pareto}(a^*, b^*)$  com  $a^* = \max\{y_1, \dots, y_n, a\}$  e  $b^* = n + b$ .

Conclusão: as distribuições *a priori*  $\theta \sim \text{Pareto}(a, b)$  e *a posteriori*  $\theta|\mathbf{Y} \sim \text{Pareto}(a^*, b^*)$  são da família Pareto.